Pronóstico de siniestros viales con víctimas en Bogotá D.C. con redes recurrentes

Actividad 2 · Reporte técnico: ejecución, optimización y validación comparativa
Técnicas Avanzadas de Modelado en IA · Maestría en Inteligencia Artificial · Universidad de La Sabana

Grupo 7: Diego Ríos Gómez · Marlon Umbarila Ortega · Nicolás Gamboa Hidalgo · Nataly Valbuena López

Resumen

Implementamos en PyTorch redes GRU y LSTM para pronosticar los siniestros con heridos o muertos de Bogotá a 1–7 días (entrenamiento 2015–2022 sin el periodo de pandemia, validación 2023, prueba 2024–2025). Tras una rejilla de 32 configuraciones, la mejor red en validación es la GRU: reduce el MAE de validación 5,1 % frente a Ridge con rezagos (mejor línea base en validación) y cumple el criterio de éxito. En prueba su MAE es 5,35 ± 0,05 siniestros/día (3 semillas), 2,3 % menor que Ridge con rezagos; la LSTM obtiene 5,35. La evidencia estadística es mixta: la LSTM supera a Ridge con rezagos con significancia (Diebold–Mariano, p = 0,04), la GRU no (p = 0,39). El calendario futuro es el componente con más aporte; la lluvia no aporta de forma robusta.

1. Pipeline e implementación de la red

El código está organizado como repositorio (config/, src/, scripts/, tests/, notebooks/). Todos los parámetros fijos, incluido el periodo atípico de pandemia, viven en config/config.yaml. El flujo es:

extracción de las bases del Anuario → serie diaria y calendario (src/data.py) → tensores por origen móvil (src/models_dl.py) → entrenamiento con parada temprana → predicción y métricas (src/metrics.py) → comparación final (scripts/run_evaluacion.py).

Ocho pruebas automáticas verifican la continuidad de la serie, el orden del split, la exclusión de la pandemia y que ninguna entrada contenga información posterior al origen.

Bloque	Dimensión	Contenido y justificación
Entrada secuencial	W × 5 (W = 14 o 28)	log1p(y) estandarizado, seno y coseno del día de la semana, festivo, lluvia observada estandarizada. Escaladores ajustados solo con entrenamiento y sin el periodo atípico.
Capa recurrente	1 capa, 32 o 64 unidades	GRU o LSTM. Una sola capa porque hay 2.319 orígenes de entrenamiento; capas adicionales aumentan parámetros sin datos que los respalden.
Calendario futuro	7 × 12 = 84	One-hot del día de la semana + festivo, puente, víspera, quincena y diciembre de cada día a pronosticar. Conocido de antemano: no hay fuga.
Cabeza densa	(h + 84) → h → 7	Concatenación del último estado oculto con el calendario; ReLU y dropout; salida lineal de 7 valores (pronóstico directo multi-horizonte).
Pérdida y salida	MSE en escala log	Estabiliza la varianza del conteo; la predicción vuelve a la escala original con expm1.

2. Optimización y ajuste de hiperparámetros

Fijamos lo que no se compara y variamos de forma sistemática los hiperparámetros críticos: ventana de entrada {14, 28}, unidades ocultas {32, 64}, tasa de aprendizaje inicial {0,001; 0,003} y dropout {0; 0,2}, con la misma rejilla para ambas arquitecturas (32 corridas, semilla 42). Optimizador AdamW (decaimiento de pesos 1e-4, regularización L2 desacoplada), recorte de gradiente a norma 1 (estabiliza la recurrencia), reducción de la tasa a la mitad tras 10 épocas sin mejora y parada temprana con paciencia 25. Se comparan arquitecturas con el mismo criterio de parada y no con el mismo número de épocas, porque un modelo con más parámetros converge a otro ritmo. La selección usa solo el MAE de validación.

Modelo	Ventana	Unidades	Tasa	Dropout	MAE val	Épocas	Parámetros
GRU	28	32	0,001	0,2	4,954	100	7.719
GRU	28	32	0,003	0,2	4,984	39	7.719
GRU	28	32	0,001	0,0	5,008	53	7.719
LSTM	28	32	0,001	0,0	4,960	39	8.967
LSTM	28	64	0,003	0,2	4,961	39	28.167
LSTM	28	32	0,003	0,0	4,972	34	8.967

Las 32 configuraciones quedan entre 4,95 y 5,09 de MAE de validación; todas mejoran a Ridge con rezagos (5,23) y a SARIMAX (5,29), así que el resultado no depende de una configuración afortunada. La ventana de 28 días rinde

mejor que la de 14 en ambas arquitecturas (GRU 5,01 vs 5,07; LSTM 5,00 vs 5,02): cuatro semanas de historia capturan mejor el nivel reciente de la serie.

3. Monitoreo de curvas de aprendizaje

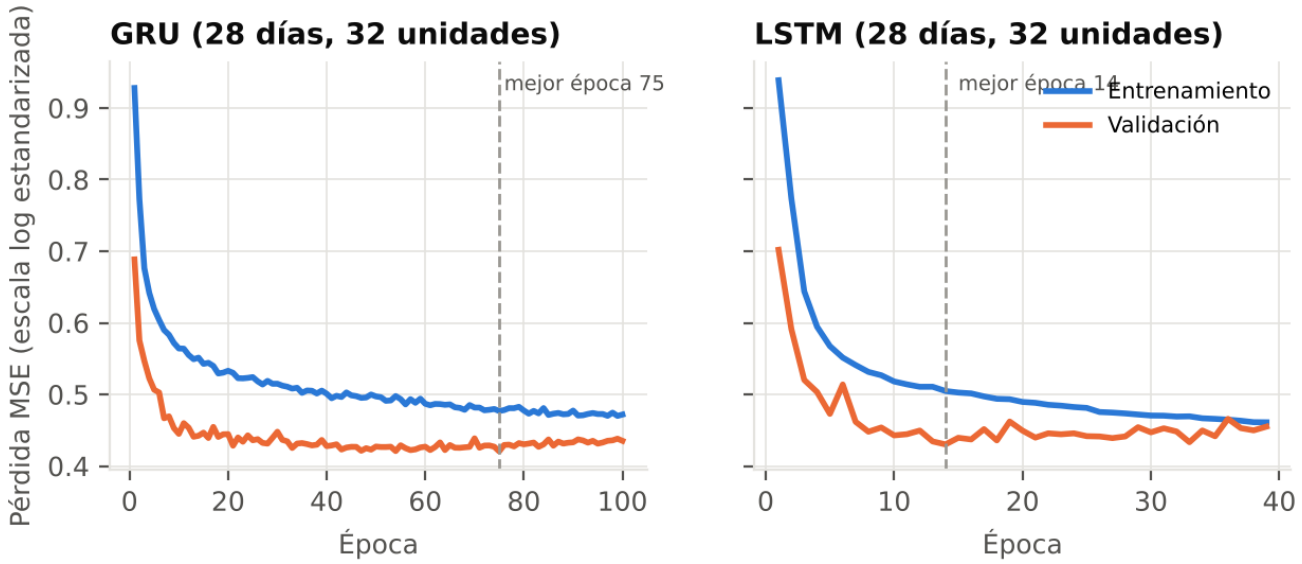


Figura 1. Pérdida de entrenamiento y validación de las configuraciones elegidas (semilla 42). La línea punteada marca la época conservada.

La pérdida de entrenamiento baja, la de validación cae en las primeras épocas y luego se estabiliza. Después de la mejor época la validación deja de mejorar mientras el entrenamiento sigue bajando: es el inicio del sobreajuste, y la parada temprana conserva los pesos anteriores. La pérdida de validación queda por debajo de la de entrenamiento porque el dropout solo actúa al entrenar y porque 2023 es un año estable, sin choques de régimen: con la pandemia excluida, entrenamiento y validación representan el mismo régimen.

4. Validación comparativa cuantitativa

Todos los modelos se evalúan sobre los mismos 726 orígenes de prueba (2024–2025) y la misma partición. Las redes se reportan como media ± desviación de tres semillas {42, 7, 2024}.

Modelo	MAE val	MAE prueba	RMSE	MAPE	RMSLE	Entreno(s)	Parám.
Naive estacional (t-7)	7,41	7,75	9,67	25,4 %	0,305	—	—
Media estacional (4 sem.)	5,97	6,27	7,88	20,8 %	0,245	—	—
Ridge con rezagos	5,23	5,47	6,80	17,6 %	0,208	5,5	—
SARIMAX	5,29	5,46	6,81	17,6 %	0,208	9,7	—
GRU	4,96	5,35 ± 0,05	6,64	17,5 %	0,205	24,3	7.719
LSTM	4,98	5,35 ± 0,03	6,64	17,5 %	0,205	5,7	8.967

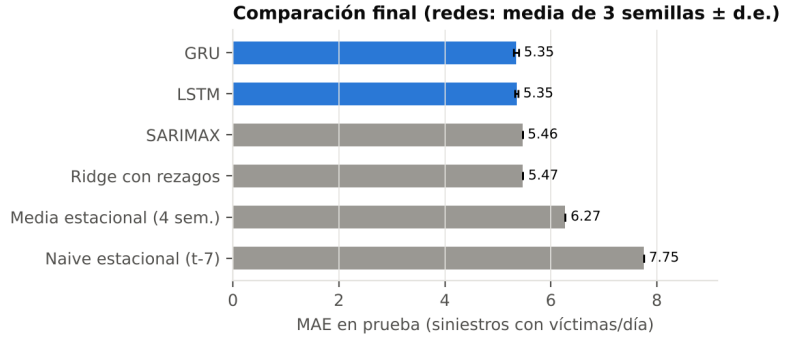


Figura 2. MAE en prueba. Gris: líneas base; azul: redes (media de 3 semillas ± d.e.).

Prueba de Diebold–Mariano. Comparamos los errores absolutos medios por origen (promedio de h = 1–7) con varianza HAC de Newey–West (rezago 7, por el solapamiento de horizontes) y la corrección de Harvey, Leybourne y Newbold. Se usa la corrida de semilla 42 de cada red.

Comparación	MAE modelo	MAE base	Δ MAE	DM (h = 1–7)	p	Lectura
GRU vs SARIMAX	5,39	5,46	-1,3 %	0,63	0,527	Diferencia no significativa
GRU vs Ridge con rezagos	5,39	5,47	-1,5 %	0,86	0,390	Diferencia no significativa
LSTM vs SARIMAX	5,33	5,46	-2,5 %	1,31	0,191	Diferencia no significativa
LSTM vs Ridge con rezagos	5,33	5,47	-2,7 %	2,06	0,040	Red mejor (p < 0,05)

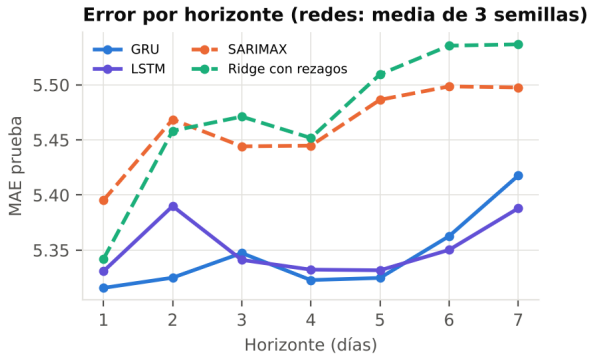


Figura 3. MAE por horizonte en prueba. Las redes quedan por debajo de ambas líneas base en los siete horizontes.

La GRU cumple el criterio en validación (−5,1 % frente a Ridge con rezagos) y conserva una ventaja menor en prueba (−2,3 %), con menor RMSE (6,64 vs 6,80). Ambas redes quedan por debajo de las dos líneas base en todos los horizontes. Pero la mejora es de 0,1 siniestros por día y solo la LSTM alcanza significancia frente a Ridge con rezagos; frente a SARIMAX ninguna red es significativa. Se elige la GRU como modelo avanzado por su desempeño en validación, sin afirmar una superioridad fuerte sobre un buen modelo lineal.

5. Experimentos de ablación (un factor a la vez)

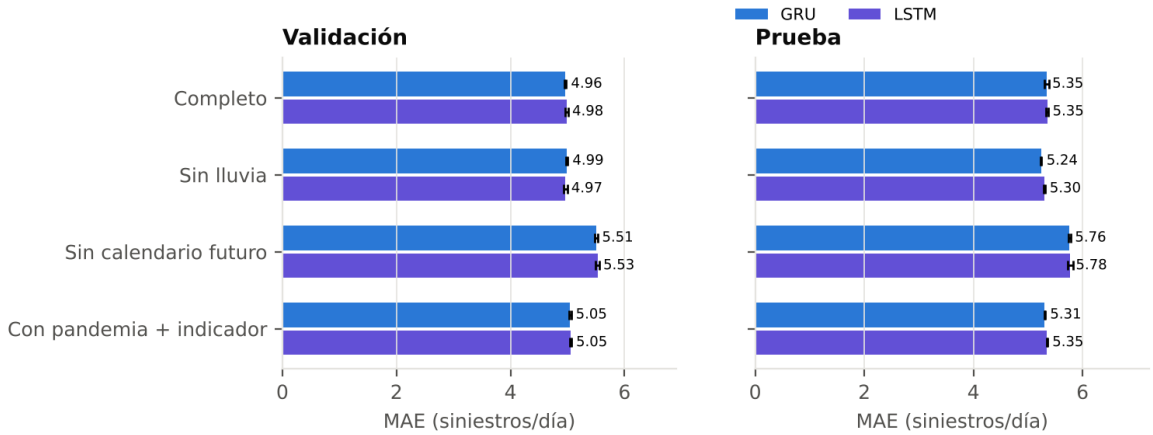


Figura 4. MAE de las variantes con la misma configuración y 3 semillas.

Calendario futuro: sin él, el MAE de prueba sube 7,8 % en la GRU y 7,9 % en la LSTM: es el componente con mayor aporte. Lluvia: sin ella, la prueba mejora levemente en ambas redes (GRU 5,24, LSTM 5,30) y la validación cambia de signo entre arquitecturas: su aporte no es robusto. Pandemia: con el periodo atípico dentro del entrenamiento (y un indicador), la validación empeora en ambas redes (GRU 5,05 vs 4,96; LSTM 5,05 vs 4,98) y las líneas base empeoran también en prueba (Ridge 5,54 vs 5,47; SARIMAX 5,51 vs 5,46). En prueba las redes casi no cambian. La exclusión se mantiene porque la decisión se toma con validación.

6. Análisis de errores

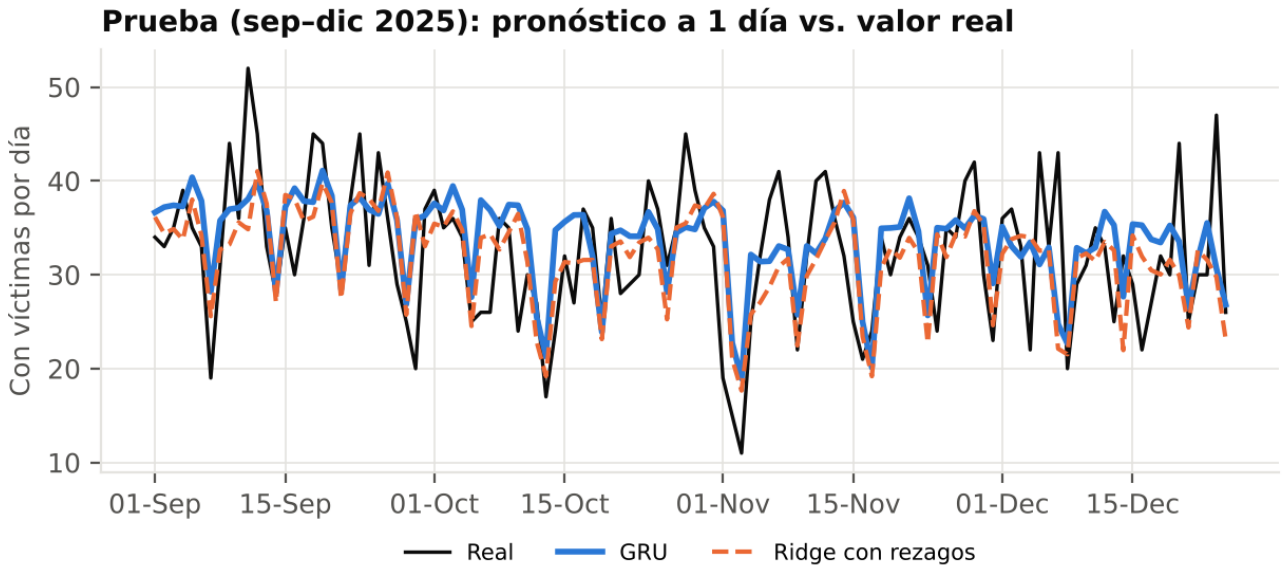


Figura 5. Pronóstico a 1 día de la GRU y de Ridge con rezagos frente al valor real (sep–dic 2025).

- Por año: el MAE de la GRU es 5,18 en 2024 y 5,60 en 2025. En 2025 la siniestralidad con víctimas bajó (31,7/día frente a 35,3 en 2024) y las redes la sobrestiman (sesgo de la LSTM +0,83/día).
- Por día de la semana (MAE GRU): mayor el sábado (6,30), martes (5,91) y jueves (5,79); menor el domingo (4,67) y el viernes (4,80).
- Peores días: 2025-12-07 (real 43), 2025-02-06 (real 16), 2025-02-12 (real 54), 2025-03-06 (real 20). Son días atípicos en ambos sentidos, como el domingo 7 de diciembre de 2025 (día de velitas, 43 siniestros con víctimas frente a ~24 de un domingo típico); ninguna variable los anticipa.
- Lluvia: el 10 % de días más lluviosos tiene más error (GRU 5,69 vs 5,36), aunque usar la lluvia observada como entrada no lo corrige.
- Festivos: MAE 5,03 frente a 5,41 en días normales: el calendario futuro los resuelve bien.

7. Oportunidades de mejora

- Pronóstico de lluvia (no la lluvia observada) como covariable futura, ya que los días lluviosos concentran más error.
- Indicador de eventos (días sin carro, velitas, partidos, paros) conocido al pronosticar.
- Modelo global por localidad (20 series): más datos para la red y un pronóstico más útil para la operación.
- Pronóstico probabilístico (cuantiles) para planear con intervalos y no solo con un valor puntual.
- Recalibrar el nivel con datos de 2025, año en que la siniestralidad con víctimas bajó.

8. Reproducibilidad y uso de IA

- *python -m scripts.extraer_anuarios → src.data → scripts.run_baselines → scripts.run_experiments → scripts.run_evaluacion* reproduce todas las cifras de este reporte (≈ 30 minutos en CPU).
- *github.com/dialrigo/pronostico-siniestros-bogota-grupo7*
- Semillas, dependencias y configuración están versionadas.
- Se usó un asistente de IA (Claude) como apoyo para código; el equipo revisó, ejecutó y validó los resultados.