Pronóstico de siniestros viales con víctimas en Bogotá D.C. con redes recurrentes: informe técnico final

Actividad 3 · Proyecto integrador · Unidad 4 · Técnicas Avanzadas de Modelado en IA · Maestría en IA · Universidad de La Sabana
Grupo 7: Diego Alejandro Ríos Gómez · Marlon [apellidos] · Nicolás [apellidos] · Nataly [apellidos] · Octubre de 2026

Resumen ejecutivo

Pronosticamos los siniestros viales con heridos o muertos de Bogotá para cada uno de los próximos 7 días, como apoyo a la planeación operativa de movilidad y atención de emergencias. Con las bases del Anuario de Siniestralidad Vial 2015–2025 (290.184 siniestros) comparamos cuatro líneas base con redes GRU y LSTM bajo la misma partición temporal, el mismo esquema de origen móvil y con la pandemia excluida del entrenamiento.

- **Resultado:** la GRU, mejor red en validación, obtiene un MAE de 4,96 en validación (Ridge con rezagos 5,23, −5,1 %) y de 5,35 ± 0,05 siniestros con víctimas/día en prueba 2024–2025 (Ridge con rezagos 5,47, −2,3 %).
- **Evidencia:** mixta. La LSTM supera a Ridge con rezagos con significancia (Diebold–Mariano, $p = 0,04$); la GRU no ($p = 0,39$); frente a SARIMAX ninguna red es significativa.
- **Aprendizaje:** el calendario futuro aporta más que la arquitectura (+7,8 % de error sin él); la lluvia observada no aporta de forma robusta; excluir la pandemia mejora la validación.
- **Datos:** los siniestros solo con daños dejaron de registrarse de forma comparable en octubre de 2022; por eso el objetivo son los siniestros con víctimas.
- **Recomendación de uso:** apoyo semanal a la planeación con revisión humana; la GRU es la opción más precisa y la Ridge una alternativa simple con desempeño cercano.

1. Contexto, problema y alcance

Bogotá registra entre 30 y 36 siniestros viales **con heridos o muertos** por día (2024: 35,3; 2025: 31,7). Son los eventos que movilizan ambulancias, agentes y equipos de atención, y los que persigue la política distrital de Visión Cero. La Secretaría Distrital de Movilidad y la Policía de Tránsito programan esos recursos con días de anticipación, hoy con promedios históricos. **Problema:** pronosticar el número de siniestros con víctimas en Bogotá para cada uno de los próximos 7 días.

Usuario y contexto de uso: analistas de planeación operativa de movilidad y atención de emergencias (uso agregado de ciudad). **Alcance:** serie diaria de la ciudad, horizonte 1–7 días, pronóstico puntual. **Fuera de alcance:** siniestros solo con daños (su registro cambió en 2022, sección 4), pronóstico por localidad u hora, causalidad y asignación automática de recursos.

Pregunta experimental. Bajo la misma partición temporal y la misma información disponible en cada origen de pronóstico, ¿una red recurrente (GRU o LSTM) que combina la historia reciente con el calendario futuro reduce el MAE a 1–7 días frente a SARIMAX y a una regresión Ridge con rezagos? Preguntas secundarias, un factor a la vez: ¿aporta la lluvia observada?, ¿aporta el calendario futuro?, ¿conviene excluir la pandemia del entrenamiento?

2. Procedencia, licencia y composición de los datos (datasheet)

Atributo	Siniestros (variable objetivo)	Clima diario
Fuente	Anuario de Siniestralidad Vial de Bogotá, Secretaría Distrital de Movilidad (SDM), Observatorio de Movilidad. Bases en Excel construidas desde el SIGAT con los informes policiales (IPAT): la base 2024 consolida 2015–2024 y la base 2025 el año 2025.	Open-Meteo Historical Weather API (reanálisis ERA5), punto 4,60 N; −74,05 O; 2.586 m.
Licencia	Datos abiertos publicados por la SDM; la página de descarga no declara una licencia explícita. Se usan con atribución a la SDM y no se redistribuyen direcciones ni coordenadas.	CC BY 4.0 (atribución: “Weather data by Open-Meteo.com”).
Composición	290.184 siniestros únicos (hoja “Siniestros”): fecha, hora, localidad (20), clase y gravedad a 30 días: solo daños 160.018, con heridos 124.529, con muertos 5.489. Se usan 130.018 siniestros con víctimas.	4.018 días (2015–2025): precipitación diaria (mm) y temperatura media (°C). Sin nulos.
Cobertura	2015-01-01 a 2025-12-31; 4.018 días, ninguno sin registro.	Misma cobertura.
Limitaciones	Solo siniestros con informe policial (subregistro de eventos leves); los solo daños dejan de registrarse en forma comparable desde oct-2022; la base 2025 solo incluye siniestros con víctimas; 0,05 % sin gravedad.	Es un punto de reanálisis, no una estación: suaviza la lluvia localizada.

La primera versión del proyecto usó el “Histórico Siniestros Bogotá D.C.” de Datos Abiertos Bogotá, que no se actualiza desde octubre de 2021. Se reemplazó por las bases del Anuario, que llegan a diciembre de 2025.

3. Variable objetivo y predictores

- **Objetivo:** y_{t+h} = siniestros con heridos o muertos (indicador de gravedad a 30 días) del día t+h, h = 1…7 (pronóstico multi-horizonte directo).
- **Historia (hasta el día t):** conteos rezagados (ventana de 14 o 28 días), lluvia observada, festivos.
- **Calendario futuro (conocido de antemano, sin fuga):** día de la semana, festivo (calendario oficial colombiano), lunes festivo (puente), víspera de festivo, días de quincena y diciembre.
- **Lluvia futura:** no se usa, porque no se conoce al pronosticar; solo la lluvia ya observada.

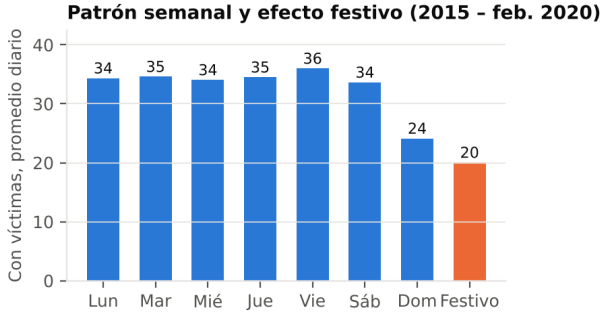


Figura 1. El calendario domina la señal: ~34 siniestros con víctimas entre semana, 24 el domingo y 20 en festivo. La correlación diaria con la lluvia es casi nula (r ≈ −0,04), por lo que su aporte se probará en vez de suponerse.

4. Auditoría inicial de calidad y decisiones

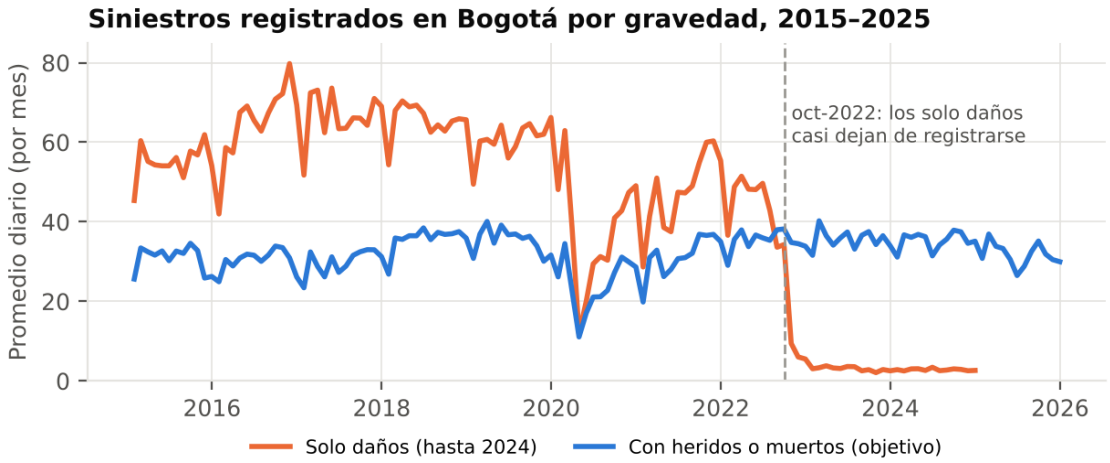


Figura 2. Desde octubre de 2022 los siniestros solo con daños caen a ~3 por día, mientras los siniestros con víctimas se mantienen estables: es un cambio en el registro, no en la siniestralidad.

Verificación	Hallazgo	Decisión
Cambio de registro	Solo daños: 17.388 en 2021, 1.115 en 2023; con víctimas: 31,4 → 35,6 por día.	Objetivo = siniestros con víctimas; el total no es comparable en el tiempo.
Duplicados	Códigos únicos en cada base; 3 códigos aparecen en las bases 2024 y 2025.	Se conserva la primera aparición.
Continuidad	0 días sin registro y 0 días sin víctimas en 4.018.	No requiere imputación.
Gravedad	Dos indicadores (tradicional y a 30 días) difieren en 88 de 118.536 siniestros con víctimas (0,07 %); 2025 solo trae el de 30 días.	Se usa el indicador a 30 días en todos los años.
Pandemia	Mar-2020 a ago-2021: promedio de 11 víctimas/día en abr-2020, cuarentenas y paro; el nivel normal (~36) vuelve en sep-2021.	Periodo atípico (534 días) excluido del entrenamiento; control con indicador.
Nivel por año	2015–2017 ≈ 30/día; 2018–2019 y 2022–2024 ≈ 35/día; 2025 = 31,7/día.	Se reporta; la prueba (2024–2025) incluye esa baja.

5. Esquema de partición y prevención de fuga de información

La unidad sobre la que se quiere generalizar es el **intervalo temporal futuro**, así que la partición es cronológica y sin mezcla: el pasado entrena y el futuro evalúa. Validación y prueba son años completos, por lo que incluyen todas las estaciones, festivos y diciembre.

Conjunto	Periodo	Días	Uso
Entrenamiento	2015-01-01 a 2022-12-31	2.922	Ajuste de parámetros y escaladores. Sin el periodo atípico: 2.319 orígenes útiles.
Validación	2023-01-01 a 2023-12-31	365	Parada temprana, selección de hiperparámetros y de modelo.
Prueba	2024-01-01 a 2025-12-31	731	Evaluación final; se usa una sola vez, al terminar.

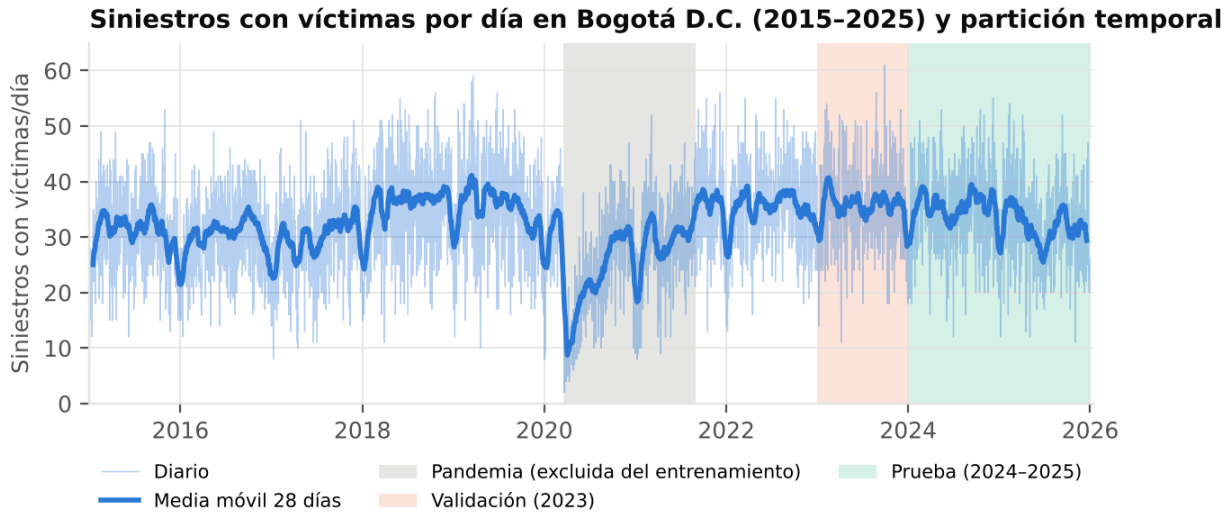


Figura 3. Serie diaria con víctimas, media móvil de 28 días, periodo atípico excluido y partición temporal.

- **Origen móvil:** en cada día t de validación o prueba se pronostican t+1…t+7 solo con datos hasta t (360 orígenes en validación y 726 en prueba). Todos los modelos usan exactamente los mismos orígenes.
- **Pandemia:** se descartan los orígenes de entrenamiento cuya ventana de entrada u objetivos tocan el 16-mar-2020 a 31-ago-2021; en SARIMAX esos días se tratan como faltantes en el filtro de Kalman.
- Normalización calculada **solo con entrenamiento** (sin el periodo atípico).
- Ningún rasgo usa información posterior al origen, excepto el calendario, que es conocido de antemano.
- Selección de hiperparámetros y de modelo **solo con validación**; la prueba no se mira hasta el final.

6. Preprocesamiento

Extracción de la hoja de siniestros de cada base (*scripts/extraer_anuarios.py*, sin dirección ni coordenadas); unión 2015–2024 + 2025 y deduplicación por código; conteo diario de siniestros con víctimas; transformación log1p (estabiliza la varianza); estandarización con estadísticos de entrenamiento; seno/coseno del día de la semana en la secuencia y one-hot en el calendario futuro; ventanas deslizantes (W = 14 o 28 días). Festivos con la librería *holidays*.

7. Métricas de éxito

Métrica	Por qué
MAE (principal)	Se interpreta directamente en siniestros con víctimas por día, la unidad con la que se dimensionan recursos.
RMSE	Penaliza más los días con error grande, los operativamente costosos (quedarse corto un día pico).
MAPE	Error relativo para usuarios no técnicos; estable porque el conteo diario casi nunca baja de 10.
RMSLE	Error en escala logarítmica, coherente con la pérdida de entrenamiento (MSE sobre log1p).

Criterio de éxito: el modelo avanzado es mejor si reduce el MAE de validación en al menos 5 % frente a la mejor línea base, la mejora se mantiene en prueba (promedio de 3 semillas) y la prueba de Diebold–Mariano sobre los errores absolutos es significativa ($p < 0{,}05$). Se reporta también el costo: tiempo de entrenamiento e inferencia y parámetros.

8. Línea base implementada y primeras métricas

Las cuatro líneas base están implementadas y son reproducibles (*python -m scripts.run_baselines*), con el mismo esquema de origen móvil a 1–7 días.

Línea base	Descripción	MAE val	MAE prueba	RMSE prueba	MAPE prueba
Naive estacional (t-7)	Repite el valor del mismo día de la semana anterior.	7,41	7,75	9,67	25,4 %
Media estacional (4 sem.)	Promedio de las 4 semanas previas para el mismo día de la semana.	5,97	6,27	7,88	20,8 %

Línea base	Descripción	MAE val	MAE prueba	RMSE prueba	MAPE prueba
Ridge con rezagos	Un modelo lineal por horizonte: 28 rezagos de log1p(y) + calendario del día objetivo.	5,23	5,47	6,80	17,6 %
SARIMAX	SARIMAX(2,0,1)(1,0,1)$_7$ en log1p(y) con festivo, puente, víspera y diciembre como exógenas.	5,29	5,46	6,81	17,6 %

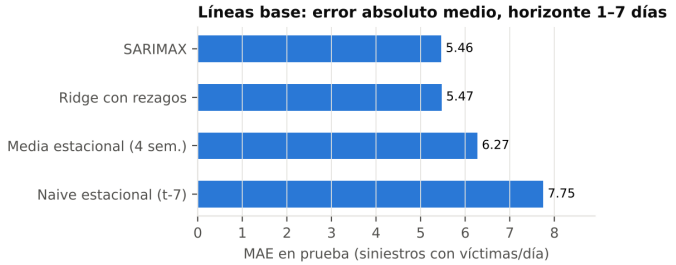


Figura 4. MAE en prueba de las líneas base. Los modelos con calendario superan a las heurísticas.

Lectura. Ridge (5,23) y SARIMAX (5,29) están prácticamente empatados en validación y mejoran a la heurística naive en ~30 %. La mejor línea base en validación es Ridge con rezagos; el umbral de éxito del modelo avanzado es un MAE de validación ≤ 4,97. **Control de pandemia:** con el periodo atípico dentro del entrenamiento (y un indicador), el MAE de prueba empeora en ambas líneas base (Ridge 5,54 vs 5,47; SARIMAX 5,51 vs 5,46), lo que respalda excluirlo.

9. Pipeline e implementación de la red

El código está en el repositorio público *github.com/dialrigo/pronostico-siniestros-bogota-grupo7*, organizado en (*config/*, *src/*, *scripts/*, *tests/*, *notebooks/*). Todos los parámetros fijos, incluido el periodo atípico de pandemia, viven en *config/config.yaml*. El flujo es: extracción de las bases del Anuario → serie diaria y calendario (*src/data.py*) → tensores por origen móvil (*src/models_dl.py*) → entrenamiento con parada temprana → predicción y métricas (*src/metrics.py*) → comparación final (*scripts/run_evaluacion.py*). Ocho pruebas automáticas verifican la continuidad de la serie, el orden del split, la exclusión de la pandemia y que ninguna entrada contenga información posterior al origen.

Bloque	Dimensión	Contenido y justificación
Entrada secuencial	W × 5 (W = 14 o 28)	log1p(y) estandarizado, seno y coseno del día de la semana, festivo, lluvia observada estandarizada. Escaladores ajustados solo con entrenamiento y sin el periodo atípico.
Capa recurrente	1 capa, 32 o 64 unidades	GRU o LSTM. Una sola capa porque hay 2.319 orígenes de entrenamiento; capas adicionales aumentan parámetros sin datos que los respalden.
Calendario futuro	7 × 12 = 84	One-hot del día de la semana + festivo, puente, víspera, quincena y diciembre de cada día a pronosticar. Conocido de antemano: no hay fuga.
Cabeza densa	(h + 84) → h → 7	Concatenación del último estado oculto con el calendario; ReLU y dropout; salida lineal de 7 valores (pronóstico directo multi-horizonte).
Pérdida y salida	MSE en escala log	Estabiliza la varianza del conteo; la predicción vuelve a la escala original con expm1.

10. Optimización y ajuste de hiperparámetros

Fijamos lo que no se compara y variamos de forma sistemática los hiperparámetros críticos: ventana de entrada {14, 28}, unidades ocultas {32, 64}, tasa de aprendizaje inicial {0,001; 0,003} y dropout {0; 0,2}, con la misma rejilla para ambas arquitecturas (32 corridas, semilla 42). Optimizador AdamW (decaimiento de pesos 1e-4, regularización L2 desacoplada), recorte de gradiente a norma 1 (estabiliza la recurrencia), reducción de la tasa a la mitad tras 10 épocas sin mejora y parada temprana con paciencia 25. Se comparan arquitecturas con el mismo criterio de parada y no con el mismo número de épocas, porque un modelo con más parámetros converge a otro ritmo. La selección usa solo el MAE de validación.

Modelo	Ventana	Unidades	Tasa	Dropout	MAE val	Épocas	Parámetros
GRU	28	32	0,001	0,2	4,954	100	7.719
GRU	28	32	0,003	0,2	4,984	39	7.719
GRU	28	32	0,001	0,0	5,008	53	7.719

Modelo	Ventana	Unidades	Tasa	Dropout	MAE val	Épocas	Parámetros
LSTM	28	32	0,001	0,0	4,960	39	8.967
LSTM	28	64	0,003	0,2	4,961	39	28.167
LSTM	28	32	0,003	0,0	4,972	34	8.967

Las 32 configuraciones quedan entre 4,95 y 5,09 de MAE de validación; todas mejoran a Ridge con rezagos (5,23) y a SARIMAX (5,29), así que el resultado no depende de una configuración afortunada. La ventana de 28 días rinde mejor que la de 14 en ambas arquitecturas (GRU 5,01 vs 5,07; LSTM 5,00 vs 5,02): cuatro semanas de historia capturan mejor el nivel reciente de la serie.

11. Monitoreo de curvas de aprendizaje

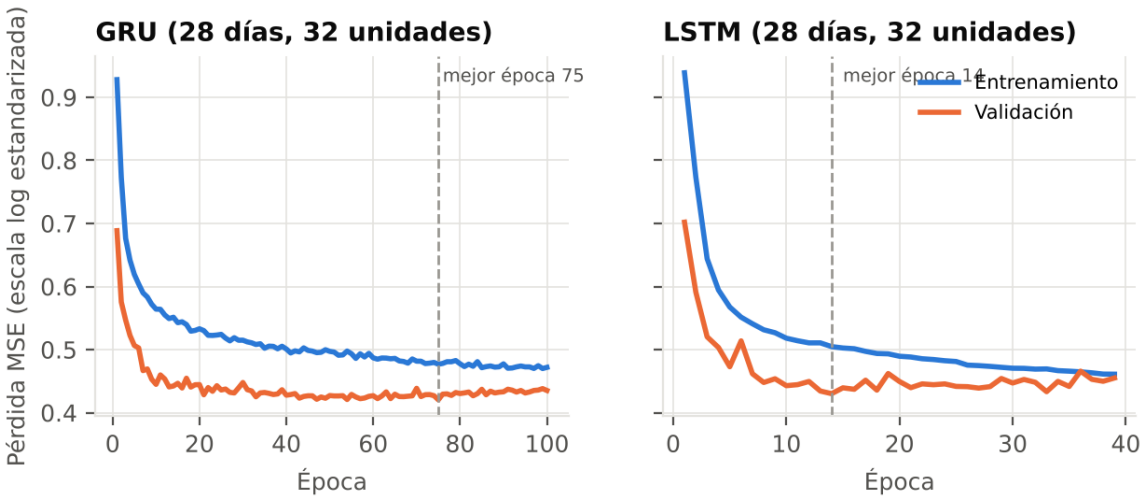


Figura 1. Pérdida de entrenamiento y validación de las configuraciones elegidas (semilla 42). La línea punteada marca la época conservada.

La pérdida de entrenamiento baja de forma monótona; la de validación cae en las primeras épocas y luego se estabiliza. Después de la mejor época la validación deja de mejorar mientras el entrenamiento sigue bajando: es el inicio del sobreajuste, y la parada temprana conserva los pesos anteriores. La pérdida de validación queda por debajo de la de entrenamiento porque el dropout solo actúa al entrenar y porque 2023 es un año estable, sin choques de régimen: con la pandemia excluida, entrenamiento y validación representan el mismo régimen.

12. Validación comparativa cuantitativa

Todos los modelos se evalúan sobre los mismos 726 orígenes de prueba (2024–2025) y la misma partición. Las redes se reportan como media ± desviación de tres semillas {42, 7, 2024}.

Modelo	MAE val	MAE prueba	RMSE	MAPE	RMSLE	Entreno (s)	Parám.
Naive estacional (t-7)	7,41	7,75	9,67	25,4 %	0,305	—	—
Media estacional (4 sem.)	5,97	6,27	7,88	20,8 %	0,245	—	—
Ridge con rezagos	5,23	5,47	6,80	17,6 %	0,208	5,5	—
SARIMAX	5,29	5,46	6,81	17,6 %	0,208	9,7	—
GRU	4,96	5,35 ± 0,05	6,64	17,5 %	0,205	24,3	7.719
LSTM	4,98	5,35 ± 0,03	6,64	17,5 %	0,205	5,7	8.967

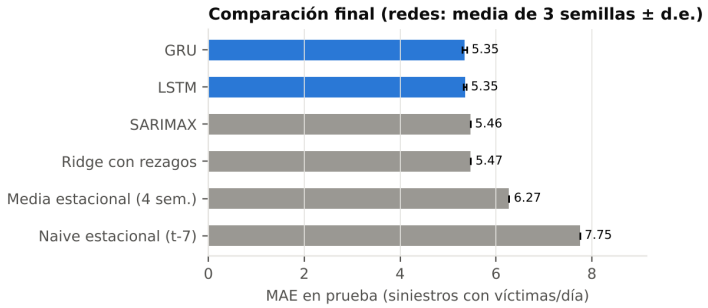


Figura 2. MAE en prueba. Gris: líneas base; azul: redes (media de 3 semillas ± d.e.).

Prueba de Diebold–Mariano. Para no afirmar superioridad con una sola cifra, comparamos los errores absolutos medios por origen (promedio de h = 1–7) con varianza HAC de Newey–West (rezago 7, por el solapamiento de horizontes) y la corrección de Harvey, Leybourne y Newbold. Se usa la corrida de semilla 42 de cada red; un estadístico positivo favorece a la red.

Comparación	MAE modelo	MAE base	Δ MAE	DM (h = 1–7)	p	Lectura
GRU vs SARIMAX	5,39	5,46	-1,3 %	0,63	0,527	Diferencia no significativa
GRU vs Ridge con rezagos	5,39	5,47	-1,5 %	0,86	0,390	Diferencia no significativa
LSTM vs SARIMAX	5,33	5,46	-2,5 %	1,31	0,191	Diferencia no significativa
LSTM vs Ridge con rezagos	5,33	5,47	-2,7 %	2,06	0,040	Red mejor (p < 0,05)

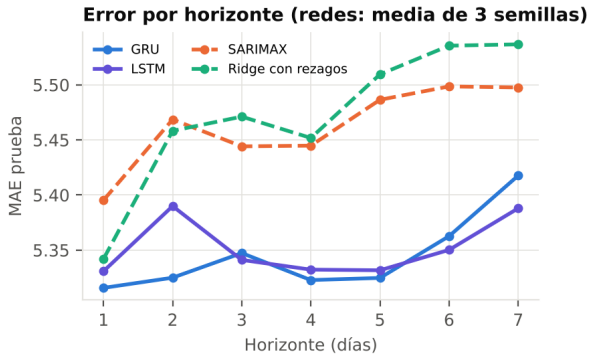


Figura 3. MAE por horizonte en prueba. Las redes quedan por debajo de ambas líneas base en los siete horizontes.

Lectura. La GRU cumple el criterio en validación (−5,1 % frente a Ridge con rezagos) y conserva una ventaja menor en prueba (−2,3 %), con menor RMSE (6,64 vs 6,80). Ambas redes quedan por debajo de las dos líneas base en todos los horizontes. Pero la mejora es de 0,1 siniestros por día y solo la LSTM alcanza significancia frente a Ridge con rezagos; frente a SARIMAX ninguna red es significativa. Se elige la GRU como modelo avanzado por su desempeño en validación, sin afirmar una superioridad fuerte sobre un buen modelo lineal.

13. Experimentos de ablación (un factor a la vez)

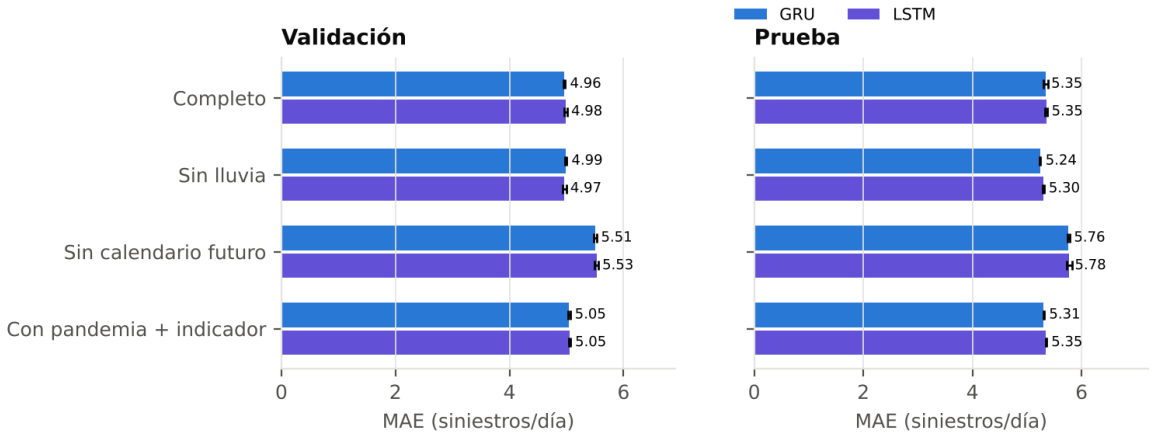


Figura 4. MAE de las variantes con la misma configuración y 3 semillas.

Calendario futuro: sin él, el MAE de prueba sube 7,8 % en la GRU y 7,9 % en la LSTM: es el componente con mayor aporte. **Lluvia:** sin ella, la prueba mejora levemente en ambas redes (GRU 5,24, LSTM 5,30) y la validación cambia de signo entre arquitecturas: su aporte no es robusto. **Pandemia:** con el periodo atípico dentro del entrenamiento (y un indicador), la validación empeora en ambas redes (GRU 5,05 vs 4,96; LSTM 5,05 vs 4,98) y las líneas base empeoran también en prueba (Ridge 5,54 vs 5,47; SARIMAX 5,51 vs 5,46). En prueba las redes casi no cambian. La exclusión se mantiene porque la decisión se toma con validación.

14. Análisis de errores

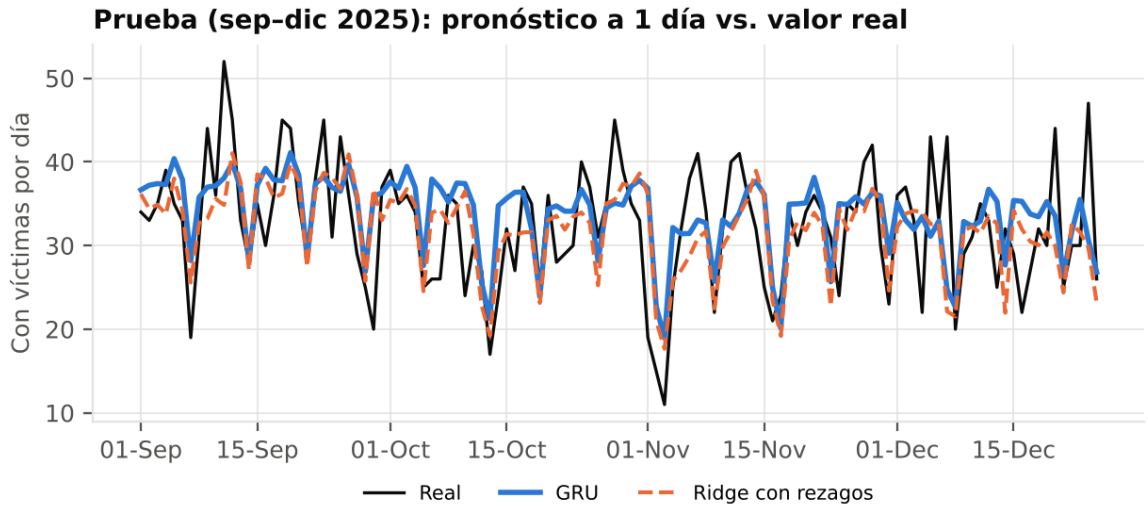


Figura 5. Pronóstico a 1 día de la GRU y de Ridge con rezagos frente al valor real (sep–dic 2025).

- **Por año:** el MAE de la GRU es 5,18 en 2024 y 5,60 en 2025. En 2025 la siniestralidad con víctimas bajó (31,7/día frente a 35,3 en 2024) y las redes la sobrestiman (sesgo de la LSTM +0,83/día).
- **Por día de la semana (MAE GRU):** mayor el sábado (6,30), martes (5,91) y jueves (5,79); menor el domingo (4,67) y el viernes (4,80).
- **Peores días:** 2025-12-07 (real 43), 2025-02-06 (real 16), 2025-02-12 (real 54), 2025-03-06 (real 20). Son días atípicos en ambos sentidos, como el domingo 7 de diciembre de 2025 (día de velitas, 43 siniestros con víctimas frente a ~24 de un domingo típico); ninguna variable los anticipa.
- **Lluvia:** el 10 % de días más lluviosos tiene más error (GRU 5,69 vs 5,36), aunque usar la lluvia observada como entrada no lo corrige.
- **Festivos:** MAE 5,03 frente a 5,41 en días normales: el calendario futuro los resuelve bien.

15. Ficha del modelo (model card)

Campo	Contenido
Modelo	GRU de 1 capa (32 unidades. ventana de 28 días. dropout 0.2) + cabeza densa con calendario futuro; 7.719 parámetros; PyTorch.
Uso previsto	Pronóstico de siniestros con heridos o muertos por día en Bogotá a 1–7 días, para dimensionar recursos de tránsito y atención con revisión humana.
Usos no previstos	Decisiones automáticas de asignación, evaluación de la seguridad de una zona o persona, pronóstico por localidad u hora, siniestros solo con daños.
Entradas	28 días de historia de conteos, lluvia observada, día de la semana y festivos; calendario de los 7 días futuros.
Datos de entrenamiento	Anuario de Siniestralidad Vial (SDM), 2015–2022 sin el periodo 16-mar-2020 a 31-ago-2021; validación 2023.
Desempeño (prueba)	MAE 5,35 ± 0,05; RMSE 6,64; MAPE 17,5 % (2024–2025, 3 semillas).
Costo	Entrenamiento ≈ 24 s en CPU; inferencia de 726 orígenes < 1 s.
Limitaciones	No anticipa días atípicos (velitas, eventos); sobrestima en 2025, año con menos siniestralidad; mayor error en días muy lluviosos.
Mantenimiento	Monitorear el MAE semanal; reentrenar cada año o ante cambios de política de movilidad o del registro de siniestros.

16. Riesgos de sesgo, privacidad, seguridad y uso indebido

Riesgo	Descripción	Mitigación
Sesgo de medición	Solo hay eventos con informe policial; el registro cambió en 2022 y puede volver a cambiar.	Objetivo restringido a siniestros con víctimas, el más estable; monitorear el registro y declararlo.
Cambio de régimen	Pandemia, paros y medidas de movilidad cambian la relación histórica.	Periodo atípico excluido, validación en 2023, monitoreo del error y reentrenamiento.
Privacidad	Las bases incluyen direcciones, coordenadas y, en otras hojas, edad y sexo de víctimas.	Solo se extraen fecha, hora, localidad, clase y gravedad; se publican conteos diarios agregados.
Uso indebido	Asignar recursos solo con el pronóstico podría desatender días atípicos (eventos masivos, paros).	Uso como apoyo a la decisión, con error reportado y revisión humana.
Seguridad	Repositorio público.	Sin credenciales ni rutas locales; dependencias fijadas en *requirements.txt*.

La clasificación sigue las funciones del NIST AI RMF 1.0 (mapear, medir, gestionar).

17. Resultados, interpretación y conclusiones

Resultados

La GRU reduce el MAE frente a Ridge con rezagos en validación (4,96 vs 5,23, −5,1 %) y en prueba (5,35 vs 5,47, −2,3 %). Ambas redes quedan por debajo de las dos líneas base en los siete horizontes. Sin calendario futuro el error sube 7,8 %; sin lluvia el efecto es pequeño y de signo cambiante; con la pandemia dentro del entrenamiento la validación empeora.

Interpretación

La estructura principal del problema (estacionalidad semanal y festivos) la captura bien un modelo lineal con rezagos. La red agrega una mejora pequeña pero consistente en todos los horizontes, de unos 0,1 siniestros por día, que solo en un caso alcanza significancia estadística. Su costo de ajuste (rejilla, semillas, parada temprana) es mayor.

Conclusiones

- Respondiendo la pregunta experimental: la red recurrente reduce el error frente a SARIMAX y Ridge, pero la mejora es pequeña y la evidencia estadística es mixta.
- La mejora más grande proviene de la información correcta (calendario futuro sin fuga) y de datos consistentes (objetivo con víctimas, pandemia excluida), no de la complejidad del modelo.
- El siguiente paso con mayor potencial es un modelo global por localidad, pronóstico de lluvia como covariable y un indicador de eventos.

18. Reproducibilidad del repositorio

Elemento	Detalle
Estructura	config/ · src/ · scripts/ · notebooks/ · results/ · figures/ · docs/ · tests/ · README.md · requirements.txt
Ejecución	pip install -r requirements.txt → python -m scripts.extraer_anuarios → python -m src.data → python -m scripts.run_baselines → python -m scripts.run_experiments → python -m scripts.run_evaluacion → pytest -q
Semillas	Global 42; finales {42, 7, 2024}; permutación de lotes con generador sembrado.
Dependencias	Python 3.13; pandas 3.0, numpy 2.5, scikit-learn 1.9, statsmodels 0.15, torch 2.14, holidays 0.106 (versiones fijadas).
Datos	Crudos en data/raw con enlace, licencia y fecha de descarga en el README.
Repositorio	https://github.com/dialrigo/pronostico-siniestros-bogota-grupo7

19. Contribución del equipo

Integrante	Rol principal	Responsabilidades
Diego Ríos	Líder técnico y datos	Formulación, auditoría, pipeline de datos, integración del informe.
Marlon	Modelos clásicos	Líneas base, SARIMAX, Ridge, prueba de Diebold–Mariano.
Nicolás	Modelos profundos	GRU/LSTM, rejilla de hiperparámetros, curvas de aprendizaje.
Nataly	Evaluación y comunicación	Análisis de errores, riesgos y ética, ficha del modelo, presentación.

20. Declaración de uso de herramientas de IA

El equipo usó un asistente de IA (Claude, de Anthropic) como apoyo para escribir código, generar figuras y redactar borradores. Todas las decisiones de diseño experimental fueron revisadas por el equipo, el código se ejecutó y las cifras de este informe provienen de los archivos de resultados del repositorio.

Referencias

Secretaría Distrital de Movilidad. Anuario de Siniestralidad Vial de Bogotá 2024 y 2025 (bases en Excel). Observatorio de Movilidad de Bogotá. https://observatorio.movilidadbogota.gov.co/publicaciones/anuarios

Zippenfenig, P. (2023). Open-Meteo.com Weather API. https://open-meteo.com

Gebru, T. et al. (2021). Datasheets for Datasets. Communications of the ACM, 64(12), 86–92.

Zinkevich, M. Rules of Machine Learning: Best Practices for ML Engineering. Google.

Scikit-learn Developers. Common pitfalls and recommended practices.

NIST (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1.

Diebold, F. X. y Mariano, R. S. (1995). Comparing Predictive Accuracy. Journal of Business & Economic Statistics, 13(3), 253–263.